

Mẫu REPORT PROJECT 1

- I. Cấu trúc của 1 urls
 - Viết rõ cấu trúc đầy đủ các phần
 - Lấy 1 ví dụ và phân tích về 1 url có cả username và password
- II. Điểm giống

Contents

1	System Overview	3
2	Training Data Sources	3
2.1	Primary Dataset: Kaggle Malicious Phish Corpus	3
2.2	Supplementary Dataset: URLhaus Malware Feed	3
2.3	Whitelist Reference: Trusted Domain Catalogue	4
3	Processing Pipeline	4
3.1	URL Normalisation	5
3.2	URL Decomposition	6
3.3	Inference Pipeline	7
4	Feature Engineering	7
4.1	Group 1: Structural and Presence Features ($n = 14$)	8
4.2	Group 2: Length Features ($n = 6$)	9
4.3	Group 3: Statistical and Entropy Features ($n = 6$)	9
4.4	Group 4: Special Character Features ($n = 11$)	10
4.5	Group 5: Lexical and Heuristic Features ($n = 16$)	11
4.5.1	Levenshtein Similarity with the Whitelist	12
4.5.2	Suspicious Keyword Taxonomy	13
4.6	Group 6: Advanced Cyber Threat Indicators ($n = 10$)	13
4.7	Feature Summary	15
5	Model Training	15
5.1	Data Preprocessing	15
5.1.1	Label Encoding	15
5.1.2	Feature Matrix Construction	16
5.1.3	Deduplication	16
5.2	Data Partitioning via Stratified Group K -Fold	16
5.3	LightGBM Hyperparameter Configuration	17
5.4	Training Procedure	18
5.5	Evaluation Results	19
6	Model Architecture	19
6.1	Gradient Boosted Decision Trees	19
6.2	Objective Function	20
6.3	Class Balancing	20
6.4	Multi-Layer Regularisation Strategy	20
7	Model Persistence and Artifacts	21
8	Conclusion	21
8.1	Limitations and Future Work	22

Lấy phần giống dựa trên cấu trúc trên

III. Tài liệu tham khảo (cập nhật thêm vào references)

- <https://www.rfc-editor.org/rfc/rfc3986.html> (cấu trúc và cú pháp cho url)
- https://www.researchgate.net/publication/400715013_Deep_Learning-Based_Detection_of_Phishing_URLs_Using_URL_Structure_and_Character-Level_Features (độ quan trọng và ảnh hưởng của 1 số ký tự như '-', '/', '@', '.', '%' lên từng phần khác nhau của url)
- <https://lightgbm.readthedocs.io/en/stable/> (tài liệu về mô hình lightgbm)
- https://scikit-learn.org/stable/user_guide.html (tài liệu về thư viện scikit learn)
- <https://people.math.harvard.edu/~ctm/home/text/others/shannon/entropy/entropy.pdf> (tài liệu cho Shannon Entropy)

IV. Những khuyết điểm, điểm yếu đã biết và nêu cách sửa (nâng cấp và thêm vào phần limitation và future work)

- Kiến trúc của mô hình hiện tại đang dựa hoàn toàn vào model ML để có thể đoán URL, do đó nên dù model cho ra độ chính xác lên đến hơn 93% nhưng nó lại phụ thuộc hoàn toàn vào dữ liệu đưa vào để train model, do đó nên khi test thử những url đơn giản chỉ gồm domain + suffix thì model sẽ trả về phishing
 - cách khắc phục, trong tương lai sẽ thêm các lớp lọc phía trên trước khi đưa url vào model, dự kiến kiến trúc mới sẽ bao gồm 5 lớp với trình tự như sau
(normalization & de-obfuscation → unshorten & resolve → Strict exact match whitelist → feature engineering and typosquatting detection → ML Scanner(model ML gồm 4 lớp: 1 lớp dành riêng cho các ký tự đặc biệt ở từng phần của url; 1 lớp dành cho độ dài và entropy; 1 lớp dành cho phân tích url động; 1 lớp dành cho nhóm các từ khóa lạ, gắn cờ cho các nhóm suffix, gắn cờ khi thấy các từ khóa lạ,...)
 - Tối ưu lại các tham số cho mô hình lightgbm
 - Hiện tại mô hình đang chủ yếu tập trung vào url tĩnh, nâng cấp thêm phần hoạt động của url như (nội dung, ngày tạo,)
 - Viết thêm những tool để tự động cập nhật thêm dữ liệu làm giàu dataset mỗi tuần 1 lần
- NOTES:
 - Viết 1 bản báo cáo mới dựa trên báo cáo cũ
 - Thêm vào những phần đã chỉ dẫn bên trên

- Phần pipeline sử dụng pipeline cũ ở bên trên, và vẽ thêm 1 pipeline dự kiến ở phần limitation and future work
-